Laporan Praktikum 4

Association Rule

Dataset: Online Retail - Frequent Pattern Mining

Bima Satriawan
NRP: 5054251031

1 Pendahuluan

1.1 Latar Belakang

Association Rule merupakan salah satu metode data mining yang digunakan untuk menemukan pola hubungan antar-item dalam kumpulan transaksi. Pada konteks bisnis ritel, metode ini dapat digunakan untuk mengetahui produk-produk yang memiliki kecenderungan dibeli secara bersamaan.

Pola pembelian bersama dapat digunakan sebagai dasar dalam penyusunan strategi bundling, rekomendasi produk, promosi silang, *cross-selling*, dan penempatan produk. Pada praktikum ini, Association Rule diterapkan pada dataset *Online Retail* menggunakan algoritma FP-Growth.

Algoritma FP-Growth digunakan untuk menemukan kombinasi produk yang sering muncul dalam transaksi. Kombinasi tersebut kemudian digunakan untuk membentuk aturan asosiasi dan dievaluasi berdasarkan support, confidence, dan lift.

1.2 Tujuan

Tujuan praktikum ini adalah:

1. Memahami konsep dan penerapan Association Rule pada data transaksi.
2. Membersihkan dan menyiapkan dataset transaksi.
3. Mengubah data menjadi format transaksi berbasis invoice.
4. Mengubah transaksi menjadi bentuk one-hot basket.
5. Menemukan frequent itemset menggunakan FP-Growth.
6. Membentuk dan mengevaluasi aturan asosiasi.
7. Menginterpretasikan aturan berdasarkan support, confidence, dan lift.

1.3 Konsep Dasar Association Rule

Bentuk umum aturan asosiasi adalah:

$$A \rightarrow B$$

A disebut sebagai *antecedent*, yaitu item atau kelompok item pada bagian "jika". B disebut sebagai *consequent*, yaitu item atau kelompok item pada bagian "maka".

Aturan $A \rightarrow B$ menunjukkan bahwa transaksi yang mengandung A memiliki kecenderungan untuk turut mengandung B. Association Rule menunjukkan keterkaitan antarpoduk, tetapi tidak membuktikan bahwa pembelian A menyebabkan pembelian B.

Support mengukur proporsi seluruh transaksi yang memuat antecedent dan consequent secara bersamaan.

$$\text{support}(A \rightarrow B) = \frac{n(A \ \text{ dan } \ B)}{N}$$

Confidence menunjukkan proporsi transaksi yang memuat consequent di antara transaksi yang memuat antecedent.

$$\text{confidence}(A \rightarrow B) = \frac{n(A \ \text{ dan } \ B)}{n(A)}$$

Lift membandingkan confidence aturan dengan peluang consequent muncul secara umum.

$$\text{lift}(A \rightarrow B) = \frac{\text{confidence}(A \rightarrow B)}{\text{support}(B)}$$

Interpretasi nilai lift adalah:

- Lift lebih dari 1 menunjukkan asosiasi positif.
- Lift sama dengan 1 menunjukkan hubungan relatif independen.
- Lift kurang dari 1 menunjukkan asosiasi negatif.

Support, confidence, dan lift perlu dievaluasi secara bersama-sama. Confidence yang tinggi belum tentu menarik apabila consequent memang sangat populer. Sebaliknya, lift tinggi belum tentu berdampak besar apabila support terlalu rendah.

2 Eksplorasi Awal Dataset

Dataset yang digunakan adalah *Online Retail* dengan 541.909 baris dan 8 kolom. Dataset mencatat transaksi ritel daring dan mempunyai atribut sebagai berikut.

No.	Kolom	Tipe Data	Keterangan
1	InvoiceNo	Object	Nomor unik transaksi atau invoice.
2	StockCode	Object	Kode unik produk.
3	Description	Object	Nama atau deskripsi produk.
4	Quantity	Integer	Jumlah unit produk dalam transaksi.
5	InvoiceDate	Object	Waktu terjadinya transaksi.
6	UnitPrice	Float	Harga per unit produk.
7	CustomerID	Float	Identitas pelanggan.
8	Country	Object	Negara pelanggan.

Tabel 1: Tabel 1: Struktur atribut dataset Online Retail

`InvoiceNo` digunakan sebagai identitas transaksi, sedangkan `Description` digunakan sebagai identitas item yang mudah dibaca. Satu invoice dapat muncul pada beberapa baris karena setiap baris merepresentasikan satu jenis produk dalam transaksi.

2.1 Missing Values

Pemeriksaan missing value menemukan nilai kosong pada `CustomerID` dan `Description`.

Kolom	Jumlah Missing	Persentase	Keputusan
CustomerID	135.080	24,93%	Dipertahankan
Description	1.454	0,27%	Dihapus
Quantity	0	0,00%	Dipertahankan
InvoiceDate	0	0,00%	Dipertahankan
UnitPrice	0	0,00%	Dipertahankan
Country	0	0,00%	Dipertahankan

Tabel 2: Tabel 2: Hasil pemeriksaan missing values

Missing value pada `CustomerID` tidak dihapus karena kolom tersebut tidak digunakan untuk membentuk basket transaksi. Baris dengan `Description` kosong dihapus karena nama produk tidak dapat diidentifikasi.

2.2 Statistik Deskriptif

Statistik deskriptif pada `Quantity` dan `UnitPrice` menunjukkan rentang nilai yang cukup besar.

Statistik	Quantity	UnitPrice
Count	541.909	541.909
Mean	9,552	4,611
Standard deviation	218,081	96,760
Minimum	−80.995	−11.062,06
Kuartil pertama	1	1,25
Median	3	2,08
Kuartil ketiga	10	4,13
Maksimum	80.995	38.970

Tabel 3: Tabel 3: Statistik deskriptif Quantity dan UnitPrice

Nilai minimum `Quantity` sebesar −80.995 menunjukkan adanya quantity negatif. Quantity negatif tidak merepresentasikan penambahan produk dalam transaksi pembelian yang berhasil sehingga perlu dikeluarkan sebelum pembentukan basket.

3 Pembersihan Data

3.1 Transaksi Pembatalan

Transaksi pembatalan ditandai oleh `InvoiceNo` yang diawali huruf `C`. Hasil pemeriksaan menemukan 9.288 baris transaksi pembatalan yang berasal dari 3.836 invoice unik.

Jumlah baris pembatalan lebih besar daripada jumlah invoice pembatalan karena satu invoice dapat berisi beberapa produk yang dicatat dalam baris berbeda.

3.2 Quantity Nonpositif

Pemeriksaan pada kolom `Quantity` menghasilkan:

- Jumlah baris dengan `Quantity < 0`: 10.624.
- Jumlah baris dengan `Quantity = 0`: 0.
- Jumlah baris dengan `Quantity <= 0`: 10.624.

Seluruh nilai quantity nonpositif merupakan quantity negatif. Pemeriksaan silang antara invoice pembatalan dan quantity negatif menghasilkan tabel berikut.

Kondisi	Jumlah Baris
Invoice C dan quantity negatif	9.288
Invoice C tetapi quantity positif	0
Bukan invoice C dan quantity negatif	1.336
Bukan invoice C dan quantity positif	531.285
Total	541.909

Tabel 4: Tabel 4: Hubungan invoice pembatalan dan quantity negatif

Seluruh baris invoice pembatalan juga mempunyai quantity negatif. Oleh karena itu, jumlah baris invoice pembatalan dan quantity negatif tidak boleh dijumlahkan secara langsung karena kedua kondisi saling tumpang tindih.

3.3 Hubungan Description Kosong dan Quantity

Dari 1.454 baris dengan `Description` kosong, 862 baris mempunyai quantity nonpositif dan 592 baris mempunyai quantity positif.

Kondisi	Jumlah Baris
Description kosong dan Quantity kurang dari atau sama dengan nol	862
Description kosong tetapi Quantity positif	592
Description terisi tetapi Quantity kurang dari atau sama dengan nol	9.762
Non-C, Quantity negatif, Description kosong	862
Non-C, Quantity negatif, Description terisi	474

Tabel 5: Tabel 5: Hubungan Description kosong dan Quantity

Walaupun 592 baris mempunyai quantity positif, baris tersebut tetap dihapus karena nama produk tidak dapat diidentifikasi.

3.4 Kriteria Pembersihan

Pembersihan dilakukan dengan menghapus baris yang memenuhi sedikitnya satu kondisi berikut:

1. `InvoiceNo` kosong.
2. `Description` kosong.
3. `InvoiceNo` diawali huruf `C`.
4. `Quantity` kurang dari atau sama dengan nol.

Kriteria	Jumlah Baris
InvoiceNo kosong	0
Description kosong	1.454
Invoice pembatalan	9.288
Quantity kurang dari atau sama dengan nol	10.624
Total baris unik yang dihapus	11.216

Tabel 6: Tabel 6: Hasil penerapan kriteria pembersihan

Setelah memperhitungkan tumpang tindih antar-kriteria, diperoleh 11.216 baris unik yang harus dihapus.

3.5 Hasil Pembersihan

Kondisi	Jumlah Baris	Jumlah Invoice
Sebelum pembersihan	541.909	25.900
Sesudah pembersihan	530.693	20.136
Tidak dipertahankan	11.216	5.764

Tabel 7: Tabel 7: Perbandingan data sebelum dan sesudah pembersihan

Jumlah baris berkurang dari 541.909 menjadi 530.693. Sebanyak 11.216 baris atau sekitar 2,07% dari keseluruhan data tidak dipertahankan.

Jumlah invoice unik berkurang dari 25.900 menjadi 20.136 invoice. Data bersih tetap memiliki delapan kolom dan tidak lagi mempunyai description kosong, transaksi pembatalan, maupun quantity nonpositif.

4 Persiapan Data untuk Association Rule

4.1 Pembentukan Transaksi

Data bersih dikelompokkan berdasarkan `InvoiceNo`. Setiap invoice diubah menjadi daftar produk unik.

Apabila sebuah produk muncul lebih dari sekali pada invoice yang sama, produk tersebut hanya dicatat satu kali. Hal ini dilakukan karena basket Association Rule bersifat biner dan hanya menunjukkan keberadaan produk dalam transaksi.

Hasil pengelompokan menghasilkan 20.136 transaksi. Contoh transaksi pertama adalah:

```
CREAM CUPID HEARTS COAT HANGER;
GLASS STAR FROSTED T-LIGHT HOLDER;
KNITTED UNION FLAG HOT WATER BOTTLE;
RED WOOLLY HOTTIE WHITE HEART.;
SET 7 BABUSHKA NESTING BOXES;
WHITE HANGING HEART T-LIGHT HOLDER;
WHITE METAL LANTERN.
```

4.2 Ukuran Transaksi

Statistik	Nilai
Jumlah transaksi	20.136
Rata-rata produk unik	25,82
Standar deviasi	46,79
Minimum	1
Kuartil pertama	6
Median	15
Kuartil ketiga	29
Maksimum	1.108
Transaksi dengan satu produk	1.798
Transaksi dengan lebih dari satu produk	18.338

Tabel 8: Tabel 8: Statistik jumlah produk unik per transaksi

Sebagian besar transaksi mempunyai lebih dari satu produk. Sebanyak 18.338 transaksi dapat memberikan informasi pembelian bersama, sedangkan 1.798 transaksi hanya mempunyai satu produk.

4.3 Transformasi One-Hot

Daftar transaksi diubah menjadi matriks one-hot. Baris pada matriks mewakili invoice dan kolom mewakili produk.

Nilai `true` menunjukkan bahwa produk terdapat dalam transaksi. Nilai `false` menunjukkan bahwa produk tidak terdapat dalam transaksi.

Basket yang dihasilkan mempunyai ukuran:

$$20136 \times 4052$$

Ukuran tersebut menunjukkan bahwa terdapat 20.136 transaksi dan 4.052 produk unik.

5 Penerapan FP-Growth

5.1 Parameter Algoritma

FP-Growth diterapkan untuk menemukan frequent itemset. Parameter yang digunakan ditampilkan pada tabel berikut.

Parameter	Nilai
Minimum support	0,01
Minimum confidence	0,50
Jumlah transaksi	20.136
Jumlah produk unik	4.052

Tabel 9: Tabel 9: Parameter FP-Growth dan Association Rule

Minimum support sebesar 0,01 berarti kombinasi produk harus muncul pada sedikitnya sekitar 1% dari 20.136 transaksi. Batas tersebut setara dengan sekitar 202 transaksi.

Minimum confidence sebesar 0,50 berarti consequent harus muncul pada sedikitnya 50% transaksi yang memuat antecedent.

5.2 Hasil Frequent Itemset

FP-Growth menghasilkan 1.870 frequent itemset. Lima produk tunggal dengan support tertinggi ditampilkan pada tabel berikut.

Produk	Support
WHITE HANGING HEART T-LIGHT HOLDER	11,22%
JUMBO BAG RED RETROSPOT	10,39%
REGENCY CAKESTAND 3 TIER	9,88%
PARTY BUNTING	8,37%
LUNCH BAG RED RETROSPOT	7,77%

Tabel 10: Tabel 10: Lima produk dengan support tertinggi

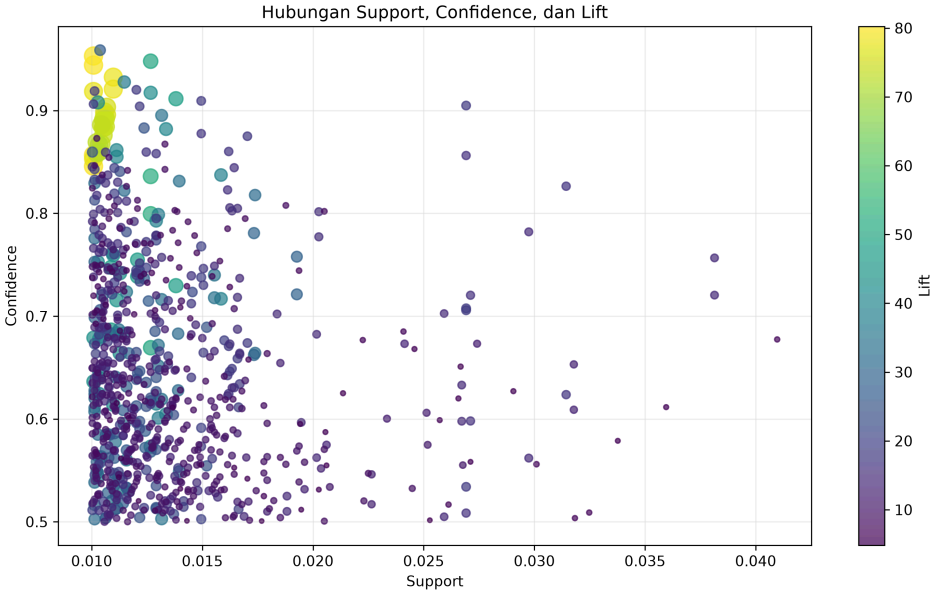
Produk `WHITE HANGING HEART T-LIGHT HOLDER` mempunyai support tertinggi sebesar 0,112237 atau sekitar 11,22%. Artinya, produk tersebut muncul pada sekitar 11,22% dari seluruh transaksi bersih.

6 Evaluasi Association Rule

6.1 Hasil Pembentukan Aturan

Dari 1.870 frequent itemset, diperoleh 871 aturan asosiasi dengan minimum confidence sebesar 0,50.

Aturan diurutkan berdasarkan lift tertinggi. Confidence dan support digunakan sebagai pengurutan tambahan ketika terdapat lift yang sama.



Gambar 1: Gambar 1: Hubungan support, confidence, dan lift

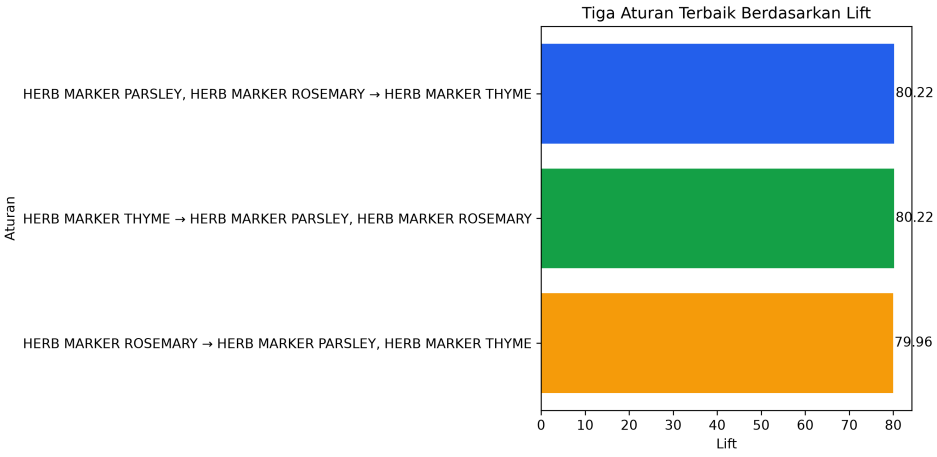
Sumbu horizontal menunjukkan support dan sumbu vertikal menunjukkan confidence. Warna dan ukuran titik menunjukkan lift.

Titik yang semakin ke kanan menunjukkan aturan yang lebih sering muncul. Titik yang semakin ke atas menunjukkan aturan yang lebih konsisten. Warna dan ukuran titik yang semakin kuat menunjukkan lift yang semakin tinggi.

6.2 Tiga Aturan Terbaik

No.	Antecedent	Consequent	Transaksi	Support	Confidence	Lift
1	HERB MARKER PARSLEY, HERB MARKER ROSEMARY	HERB MARKER THYME	203	1,01%	94,42%	80,22
2	HERB MARKER THYME	HERB MARKER PARSLEY, HERB MARKER ROSEMARY	203	1,01%	85,65%	80,22
3	HERB MARKER ROSEMARY	HERB MARKER PARSLEY, HERB MARKER THYME	203	1,01%	84,58%	79,96

Tabel 11: Tabel 11: Tiga aturan terbaik berdasarkan lift



Gambar 2: Gambar 2: Perbandingan lift tiga aturan terbaik

6.3 Interpretasi Aturan Pertama

Aturan pertama adalah:

HERB MARKER PARSLEY dan HERB MARKER ROSEMARY → HERB MARKER THYME

Support sebesar 0,010081 atau 1,01% menunjukkan bahwa kombinasi parsley, rosemary, dan thyme muncul secara bersamaan pada 203 dari 20.136 transaksi.

Confidence sebesar 0,944186 atau 94,42% menunjukkan bahwa sekitar 94,42% transaksi yang membeli parsley dan rosemary juga membeli thyme.

Lift sebesar 80,22 menunjukkan bahwa thyme sekitar 80,22 kali lebih mungkin muncul ketika parsley dan rosemary terdapat dalam transaksi dibandingkan dengan peluang thyme muncul secara umum.

6.4 Interpretasi Aturan Kedua

Aturan kedua adalah:

HERB MARKER THYME → HERB MARKER PARSLEY dan HERB MARKER ROSEMARY

Support aturan kedua sama dengan aturan pertama, yaitu 1,01%, karena kedua aturan berasal dari kombinasi produk yang sama.

Confidence sebesar 85,65% menunjukkan bahwa sekitar 85,65% transaksi yang membeli thyme juga membeli parsley dan rosemary secara bersamaan.

Lift sebesar 80,22 menunjukkan bahwa kombinasi parsley dan rosemary jauh lebih mungkin ditemukan ketika thyme terdapat dalam transaksi dibandingkan peluang kombinasi tersebut muncul secara umum.

6.5 Interpretasi Aturan Ketiga

Aturan ketiga adalah:

HERB MARKER ROSEMARY → HERB MARKER PARSLEY dan HERB MARKER THYME

Support sebesar 1,01% menunjukkan bahwa kombinasi tersebut ditemukan pada 203 transaksi.

Confidence sebesar 84,58% menunjukkan bahwa sekitar 84,58% transaksi yang membeli rosemary juga membeli parsley dan thyme secara bersamaan.

Lift sebesar 79,96 menunjukkan bahwa kombinasi parsley dan thyme sekitar 79,96 kali lebih mungkin muncul ketika rosemary terdapat dalam transaksi dibandingkan peluang kombinasi tersebut muncul secara umum.

6.6 Implikasi Bisnis

Ketiga aturan terbaik melibatkan produk dari kategori yang sama, yaitu herb marker parsley, rosemary, dan thyme. Kesamaan fungsi produk dapat menjelaskan kecenderungan produk tersebut dibeli secara bersamaan.

Penerapan bisnis yang dapat dipertimbangkan adalah:

1. Menawarkan parsley, rosemary, dan thyme sebagai satu paket produk.
2. Memberikan rekomendasi produk pelengkap.
3. Menempatkan ketiga produk secara berdekatan.
4. Menerapkan promosi silang ketika pelanggan memilih salah satu produk.

Walaupun lift ketiga aturan sangat tinggi, support-nya hanya sekitar 1,01%. Artinya, hubungan tersebut kuat pada transaksi yang relevan, tetapi kombinasi produk tidak mendominasi seluruh transaksi.

7 Dataset Akhir

Tahapan pengolahan data dan hasil akhirnya dirangkum pada tabel berikut.

Tahap	Ukuran/Hasil	Aksi
Dataset awal	(541.909, 8)	Memuat seluruh data transaksi
Pembersihan missing Description	1.454 baris	Dihapus
Pembersihan invoice pembatalan	9.288 baris	Dihapus
Pembersihan Quantity nonpositif	10.624 baris	Dihapus
Dataset bersih	(530.693, 8)	Menghasilkan 20.136 invoice
One-hot basket	(20.136, 4.052)	Matriks transaksi biner
Frequent itemset	1.870	Minimum support 0,01
Association Rule	871	Minimum confidence 0,50

Tabel 12: Tabel 12: Ringkasan hasil pengolahan data

8 Kesimpulan

1. Dataset awal memiliki 541.909 baris dan 25.900 invoice unik.
2. Pembersihan menghapus baris dengan `Description` kosong, invoice pembatalan, dan `Quantity` nonpositif.
3. Setelah pembersihan, dataset memiliki 530.693 baris dan 20.136 invoice valid.
4. Transaksi diubah menjadi basket one-hot berukuran 20.136 transaksi dan 4.052 produk.
5. FP-Growth dengan minimum support sebesar 0,01 menghasilkan 1.870 frequent itemset.
6. Association Rule dengan minimum confidence sebesar 0,50 menghasilkan 871 aturan.
7. Tiga aturan dengan lift tertinggi melibatkan herb marker parsley, rosemary, dan thyme.
8. Aturan terbaik memiliki support 1,01%, confidence 94,42%, dan lift 80,22.
9. Ketiga produk dapat dipertimbangkan sebagai kandidat bundling, rekomendasi produk, promosi silang, dan penempatan produk secara berdekatan.
10. Association Rule menunjukkan keterkaitan, bukan hubungan sebab-akibat. Oleh karena itu, support, confidence, lift, persediaan, dan margin perlu dipertimbangkan sebelum aturan diterapkan dalam keputusan bisnis.