Laporan Praktikum 1 Data Mining

Klasifikasi Transaksi Fraud dengan Ensemble Method dan Penanganan Class Imbalance

Nama: Bima Satriawan
NRP: 5054251031

1. Pendahuluan

Deteksi transaksi fraud pada kartu kredit adalah salah satu permasalahan klasifikasi yang penting di industri keuangan. Data transaksi yang tersedia umumnya memiliki distribusi kelas yang sangat tidak seimbang, di mana jumlah transaksi normal jauh lebih banyak dibandingkan transaksi fraud. Kondisi ini membuat model mudah terjebak memprediksi kelas mayoritas saja, sehingga evaluasi dengan akurasi saja tidak cukup untuk menilai performa model.

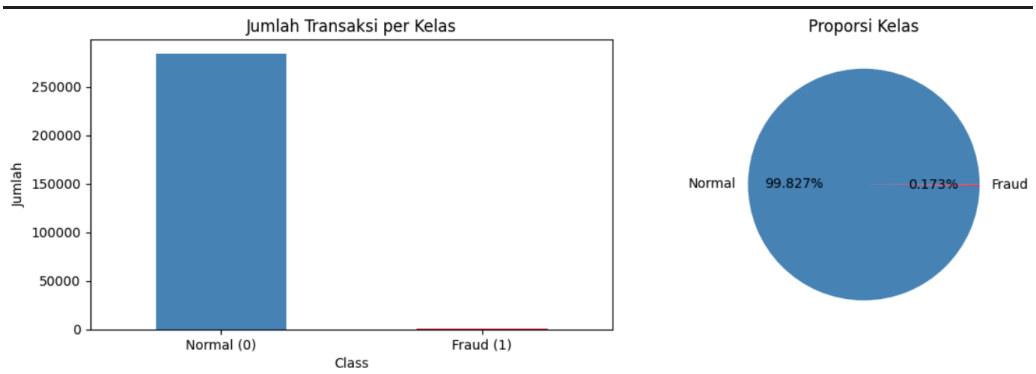
Pada praktikum ini, dibangun model klasifikasi dengan pendekatan ensemble (Random Forest, XGBoost, dan LightGBM) pada dataset Credit Card Fraud Detection. Selain itu, diterapkan beberapa teknik penanganan class imbalance seperti SMOTE dan cost-sensitive learning melalui parameter class_weight. Tujuan akhirnya adalah membandingkan performa tiap pendekatan menggunakan metrik yang sesuai untuk data tidak seimbang, yaitu precision, recall, F1-score, dan AUC.

2. Dataset dan Exploratory Data Analysis

Dataset yang digunakan adalah Credit Card Fraud Detection dari Kaggle dengan nama file `creditcard.csv`. Dataset ini memiliki 284.807 baris dan 31 kolom, terdiri dari fitur Time, Amount, 28 fitur hasil transformasi PCA (V1 sampai V28), dan kolom target Class. Nilai Class 0 menandakan transaksi normal dan Class 1 menandakan transaksi fraud.

Berdasarkan hasil eksplorasi awal, dataset tidak memiliki nilai kosong (missing value) pada seluruh kolom. Namun ditemukan 1.081 baris duplikat. Baris duplikat ini dihapus sebelum proses pemisahan data untuk menghindari kebocoran informasi antara data latih dan data uji.

Distribusi kelas awal sangat tidak seimbang. Kelas 0 mencakup 99,827 persen data sedangkan kelas 1 hanya 0,173 persen. Setelah duplikat dihapus, data latih berisi 226.602 transaksi normal dan 378 transaksi fraud, sedangkan data uji berisi 56.651 transaksi normal dan 95 transaksi fraud. Proporsi ini menunjukkan bahwa kelas minoritas hanya sekitar 0,17 persen dari keseluruhan data.



Gambar 1: Distribusi jumlah dan proporsi kelas pada dataset.

3. Preprocessing

Tahapan preprocessing dilakukan dengan memperhatikan urutan agar tidak terjadi kebocoran data dari data uji ke data latih. Data dibagi terlebih dahulu menjadi data latih dan data uji dengan perbandingan 80:20 menggunakan parameter stratify pada kolom target. Stratifikasi ini penting untuk memastikan proporsi kelas fraud tetap terjaga di kedua bagian data.

Setelah pemisahan, dilakukan standarisasi fitur numerik menggunakan StandardScaler. Seluruh proses fitting scaler hanya dilakukan pada data latih, sedangkan data uji hanya ditransformasi menggunakan parameter dari data latih. Untuk menjaga konsistensi ini, preprocessing dibungkus dalam sebuah Pipeline sehingga setiap kali model dilatih ulang, proses fitting dan transformasi berjalan otomatis dengan urutan yang benar.

Fitur Time dan Amount ikut distandarisasi karena memiliki skala yang jauh berbeda dengan fitur V1 sampai V28 yang sudah dinormalisasi melalui PCA. Tidak ada fitur kategorikal pada dataset ini sehingga tidak diperlukan proses encoding.

4. Penanganan Class Imbalance

Ada beberapa pendekatan yang digunakan untuk menangani ketidakseimbangan kelas pada data latih.

4.1. 4.1 SMOTE (Synthetic Minority Oversampling Technique)

SMOTE membuat sampel sintetis baru untuk kelas minoritas dengan cara menginterpolasi antara sampel minoritas yang berdekatan. Pada praktikum ini, SMOTE diterapkan hanya pada data latih dan tidak pada data uji. Setelah SMOTE diterapkan, jumlah sampel kelas 0 dan kelas 1 di data latih menjadi seimbang, yaitu masing-masing 226.602 sampel. Data uji tetap mempertahankan distribusi aslinya untuk mencerminkan kondisi dunia nyata.

4.2. 4.2 Cost-Sensitive Learning dengan class_weight

Pendekatan kedua adalah memberikan bobot lebih besar pada kelas minoritas melalui parameter `class_weight='balanced'` pada Random Forest. Dengan cara ini, model tidak mengubah distribusi data tetapi menyesuaikan fungsi objektifnya agar lebih memperhatikan kesalahan klasifikasi pada kelas fraud.

4.3. 4.3 Kombinasi dengan Boosting

Untuk model XGBoost digunakan parameter `scale_pos_weight`, sedangkan untuk LightGBM digunakan parameter `is_unbalance`. Kedua parameter ini berfungsi serupa dengan class_weight, yaitu memberi penalti lebih besar pada kesalahan prediksi kelas minoritas. Pada kedua model ini, SMOTE juga diterapkan bersamaan.

5. Model dan Evaluasi

Lima konfigurasi model diuji pada data uji untuk melihat performanya pada kelas fraud. Metrik yang digunakan adalah precision, recall, F1-score pada kelas fraud (kelas 1), serta ROC-AUC dan PR-AUC untuk menilai kemampuan pemisahan kelas secara keseluruhan. PR-AUC dipilih karena lebih informatif dibandingkan ROC-AUC pada data yang tidak seimbang.

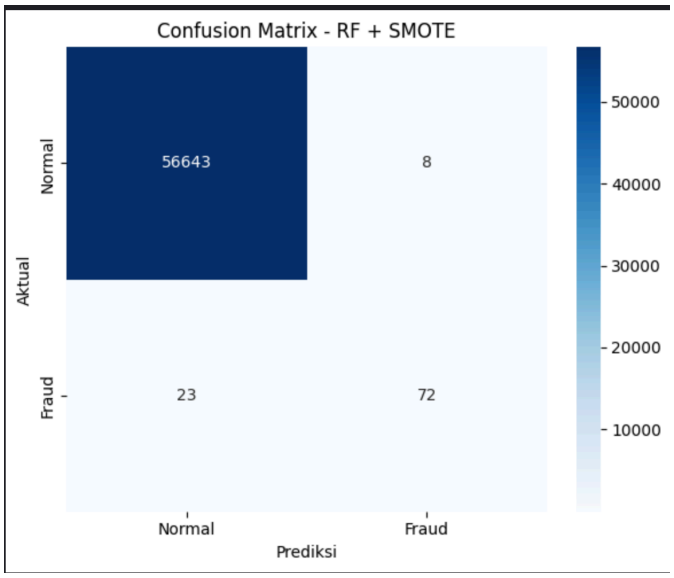
Model	Precision	Recall	F1	ROC-AUC	PR-AUC
RF baseline	0.9857	0.7263	0.8364	0.9191	0.7958
RF class_weight	0.9855	0.7158	0.8293	0.9351	0.8084
RF SMOTE	0.9000	0.7579	0.8229	0.9584	0.8072
XGB SMOTE	0.6609	0.8000	0.7238	0.9579	0.8010
LGBM SMOTE	0.5571	0.8211	0.6638	0.9756	0.7477

Tabel 1: Perbandingan performa model pada data uji.

Model Random Forest tanpa penanganan imbalance (RF baseline) sudah mencapai F1-score tertinggi, yaitu 0,8364. Hal ini menunjukkan bahwa Random Forest secara alami cukup tahan terhadap data tidak seimbang karena mekanisme bagging dan pemilihan subset fitur pada tiap pohon.

Penerapan SMOTE pada Random Forest menurunkan precision dari 0,9857 menjadi 0,9000, tetapi meningkatkan recall dari 0,7263 menjadi 0,7579. Artinya, model menjadi lebih agresif dalam menandai transaksi sebagai fraud, sehingga lebih banyak fraud yang tertangkap namun juga lebih banyak false positive.

Konfigurasi RF dengan class_weight menghasilkan performa yang mirip dengan RF baseline, dengan ROC-AUC sedikit lebih tinggi (0,9351). Ini menunjukkan bahwa penyesuaian bobot kelas membantu model memisahkan kedua kelas lebih baik, meskipun tidak selalu meningkatkan F1 secara signifikan.



Gambar 2: Confusion matrix untuk model Random Forest dengan SMOTE.

Confusion matrix pada model RF SMOTE menunjukkan 72 fraud berhasil terdeteksi dan 23 fraud lolos (false negative), sementara 8 transaksi normal salah diprediksi sebagai fraud. Dengan kata lain, model berhasil menangkap sekitar 76 persen dari total 95 kasus fraud pada data uji.

6. Analisis

Hasil perbandingan menunjukkan adanya trade-off yang jelas antara precision dan recall. Model tanpa SMOTE cenderung memiliki precision tinggi tetapi recall lebih rendah, yang berarti model lebih konservatif dalam menandai fraud. Sebaliknya, model dengan SMOTE memiliki recall lebih tinggi tetapi precision menurun karena lebih banyak transaksi normal yang salah ditandai.

Pemilihan model terbaik sangat bergantung pada prioritas bisnis. Pada kasus deteksi fraud, recall sering dianggap lebih penting karena biaya membiarkan fraud lolos jauh lebih besar dibandingkan biaya pemeriksaan tambahan pada transaksi yang sebenarnya normal. Namun, precision yang terlalu rendah juga dapat membebani tim verifikasi dengan terlalu banyak false alarm.

Pada tabel hasil, terlihat bahwa LightGBM dengan SMOTE mencapai ROC-AUC tertinggi (0,9756) dan recall tertinggi (0,8211). Namun precision-nya paling rendah (0,5571) sehingga F1-score-nya juga paling rendah. Ini menunjukkan bahwa LightGBM mampu memisahkan skor probabilitas dengan baik, tetapi threshold default 0,5 tidak optimal untuk model tersebut.

Sebaliknya, RF baseline memiliki F1-score tertinggi karena keseimbangan precision dan recall yang lebih baik. Ini menunjukkan bahwa pada dataset ini, Random Forest tanpa penanganan imbalance sudah cukup kuat sebagai baseline, dan penambahan SMOTE tidak selalu meningkatkan performa secara keseluruhan.

Alasan mengapa akurasi tidak digunakan sebagai metrik utama adalah karena model yang hanya memprediksi kelas mayoritas dapat mencapai akurasi di atas 99 persen tanpa mendeteksi satu pun transaksi fraud. Oleh karena itu, metrik seperti precision, recall, F1-score, dan PR-AUC jauh lebih relevan untuk menilai performa pada kelas minoritas.

7. Kesimpulan

Pada praktikum ini, telah dibangun model klasifikasi ensemble untuk mendeteksi transaksi fraud pada dataset Credit Card Fraud Detection yang memiliki distribusi kelas sangat tidak seimbang. Beberapa pendekatan penanganan imbalance telah dibandingkan, yaitu tanpa penanganan, class_weight, SMOTE, serta kombinasi SMOTE dengan boosting.

Hasil menunjukkan bahwa Random Forest tanpa penanganan imbalance sudah mampu mencapai F1-score tertinggi (0,8364), sedangkan model dengan SMOTE memberikan recall lebih tinggi dengan konsekuensi penurunan precision. LightGBM dengan SMOTE memiliki ROC-AUC tertinggi tetapi memerlukan penyesuaian threshold untuk memanfaatkan potensinya secara optimal.

Untuk pengembangan lebih lanjut, beberapa hal yang dapat dilakukan adalah threshold tuning untuk meningkatkan F1 pada model boosting, eksplorasi teknik resampling lain seperti SMOTEENN, serta penggunaan cross-validation untuk mendapatkan estimasi performa yang lebih stabil.