Laporan Praktikum 2
Praproses Data

Dataset: House Prices - Advanced Regression Techniques

Bima Satriawan
NRP: 5054251031

1 Pendahuluan

1.1 Latar Belakang

Praproses data merupakan tahap fundamental dalam pipeline *machine learning* yang bertujuan mengubah data mentah menjadi data yang bersih, konsisten, dan siap digunakan untuk pemodelan. Dataset **House Prices - Advanced Regression Techniques** dari Kaggle berisi 1460 baris dan 81 kolom yang mendeskripsikan berbagai atribut rumah seperti ukuran, tahun dibangun, kondisi, dan harga jual (`SalePrice`).

Dataset ini memiliki karakteristik menantang: banyak nilai hilang, campuran fitur numerik dan kategorik, serta outlier yang perlu ditangani dengan bijak.

1.2 Tujuan

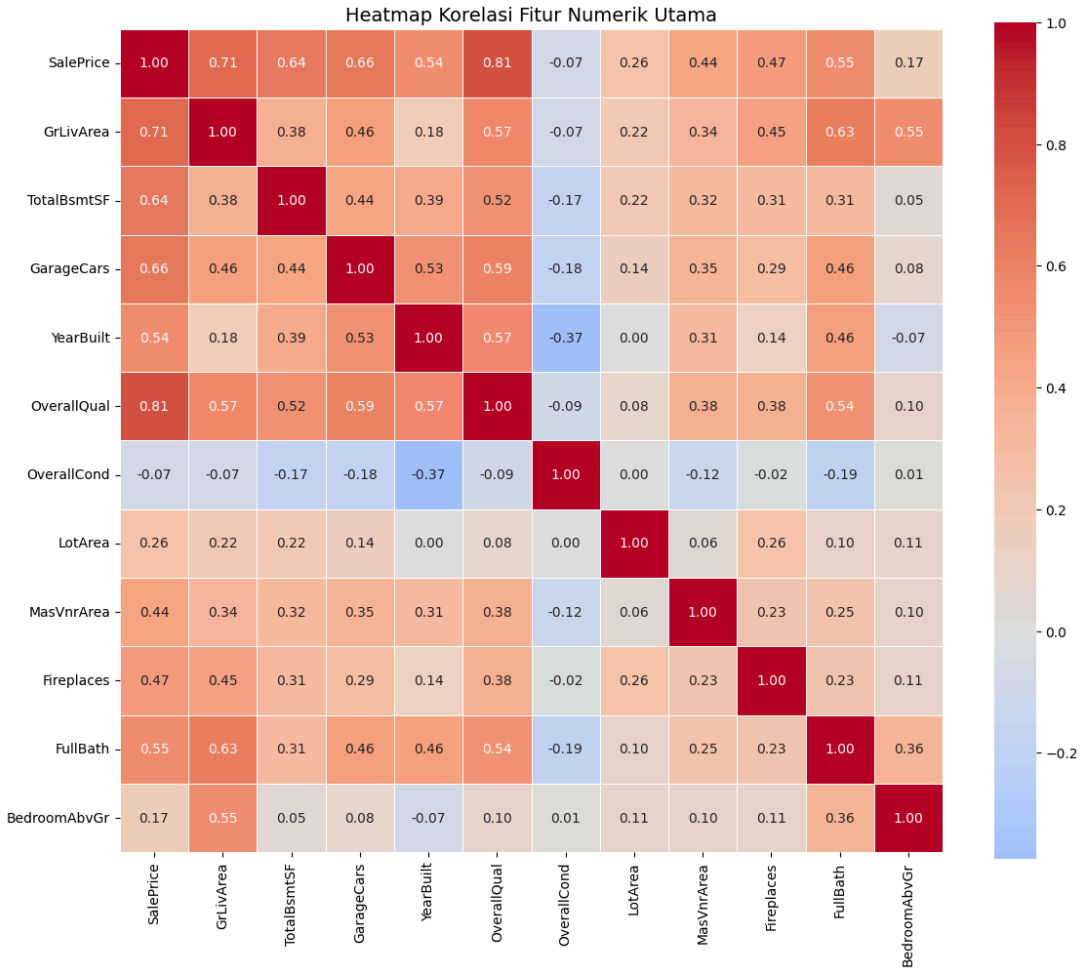
1. Memahami dan menerapkan tahapan praproses data: pembersihan, transformasi, dan reduksi dimensi.
2. Meningkatkan kualitas data melalui penanganan nilai hilang dan data tidak konsisten.
3. Menerapkan normalisasi/standarisasi dan *one-hot encoding* pada atribut yang sesuai.
4. Mereduksi dimensi menggunakan analisis korelasi dan PCA (*Principal Component Analysis*).

2 Eksplorasi Awal Dataset

Dataset dimuat menggunakan `pandas` dan diperiksa strukturnya melalui `.head()`, `.shape`, dan `.info()`.

Informasi	**Nilai**
Jumlah baris	1460
Jumlah kolom	81
Kolom numerik (int64/float64)	38
Kolom kategorik (object)	43
Kolom target	`SalePrice`

Tabel 1: Ringkasan struktur dataset House Prices



Gambar 1: Heatmap korelasi fitur numerik utama

Visualisasi korelasi menunjukkan bahwa `SalePrice` paling berkorelasi dengan `OverallQual` (0.79) dan `GrLivArea` (0.71), sedangkan `GarageCars` dan `GarageArea` saling berkorelasi tinggi (0.89) yang mengindikasikan redundansi.

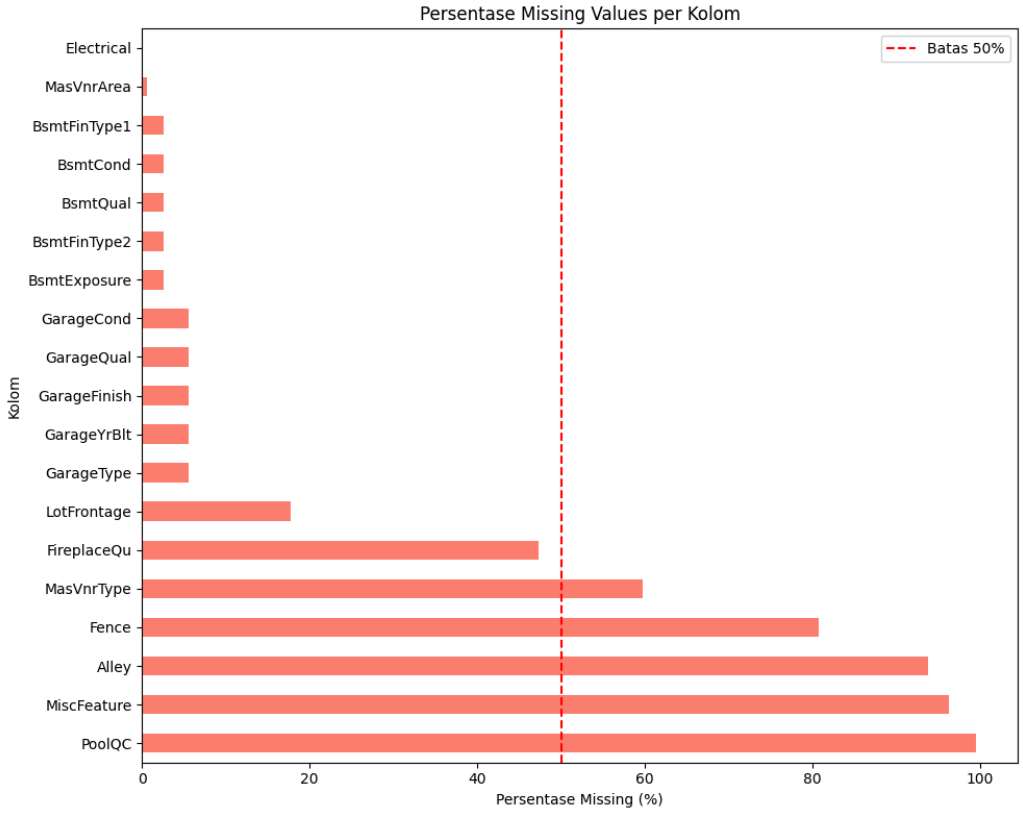
3 Pembersihan Data

3.1 Analisis Missing Values

Ditemukan **19 kolom** yang memiliki nilai hilang. Kolom dengan proporsi *missing* lebih dari 50% dihapus untuk menghindari noise.

Kolom	% Missing	Keputusan
`PoolQC`	99.52%	Dihapus
`MiscFeature`	96.30%	Dihapus
`Alley`	93.77%	Dihapus
`Fence`	80.75%	Dihapus
`MasVnrType`	59.73%	Dihapus

Tabel 2: Kolom dengan persentase missing values > 50%



Gambar 2: Persentase missing values per kolom

Setelah drop, dataset menjadi **(1460, 76)**. Kolom `FireplaceQu` (47.26%) tetap dipertahankan karena masih di bawah batas 50% dan informatif.

3.2 Penanganan Sisa Missing Values

Sisa 14 kolom yang memiliki missing ditangani dengan strategi berbeda berdasarkan makna domain:

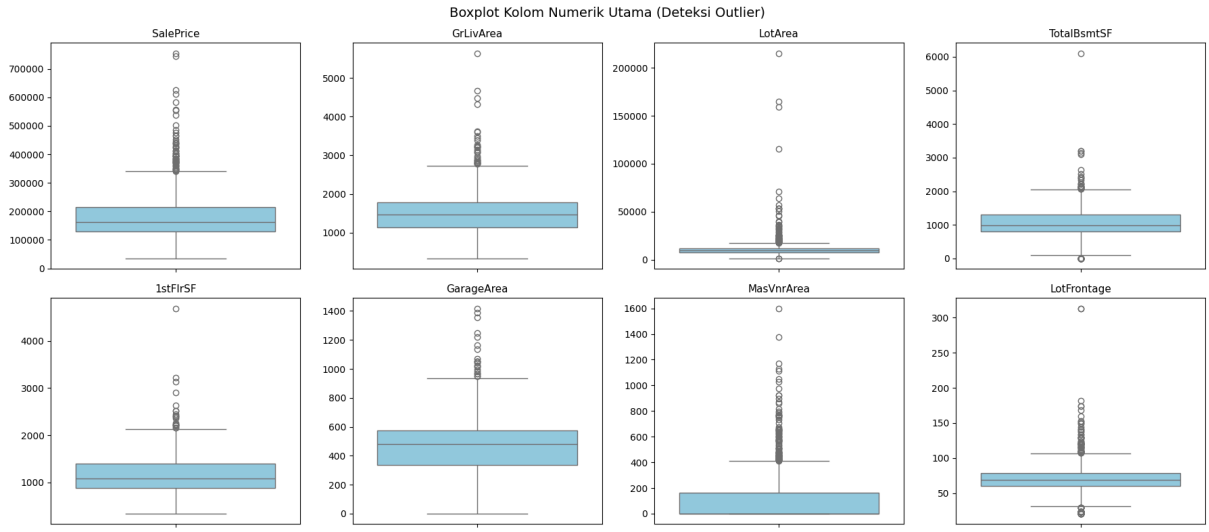
Tipe Kolom	**Strategi**	**Kolom**
Kategorik (NaN = tidak ada fitur)	Isi `"None"`	`FireplaceQu`, `GarageType`, `GarageFinish`, `GarageQual`, `GarageCond`, `BsmtQual`, `BsmtCond`, `BsmtExposure`, `BsmtFinType1`, `BsmtFinType2`
Numerik (NaN = tidak ada fitur)	Isi `0`	`GarageYrBlt`
Numerik (data hilang asli)	Isi `median`	`LotFrontage` (17.74%), `MasVnrArea` (0.55%)
Kategorik (data hilang asli)	Isi `modus`	`Electrical` (0.07%)

Tabel 3: Strategi penanganan missing values

Hasil: Total missing values = 0, shape tetap **(1460, 76)**.

4 Deteksi dan Penanganan Outlier

4.1 Deteksi dengan Boxplot



Gambar 3: Boxplot 8 kolom numerik utama untuk deteksi outlier

4.2 Perhitungan Outlier dengan Metode IQR

Metode IQR menggunakan rumus:

- $\text{IQR} = Q_3 - Q_1$
- Outlier jika $x < Q_1 - 1.5 \times \text{IQR}$ atau $x > Q_3 + 1.5 \times \text{IQR}$

Kolom	**Jumlah Outlier**
`SalePrice`	61
`GrLivArea`	31
`LotArea`	69
`TotalBsmtSF`	61
`1stFlrSF`	20
`GarageArea`	21
`MasVnrArea`	98
`LotFrontage`	106

Tabel 4: Jumlah outlier per kolom

4.3 Keputusan Penanganan Outlier

Prinsip: Tidak semua outlier dihapus. Hanya outlier yang secara *domain knowledge* tidak wajar yang dihapus.

Kolom	Keputusan	Alasan
`GrLivArea > 4000`	Dihapus	Rumah >4000 sq ft dengan harga rendah = kemungkinan data error
`SalePrice > 500000`	Dihapus	Hanya 2 data, bisa bias model
`LotArea`, `TotalBsmtSF`, dll	Dibiarkan	Outlier wajar
`MasVnrArea` (nilai 0)	Dibiarkan	Nilai 0 valid, IQR salah deteksi karena distribusi skewed

Tabel 5: Justifikasi keputusan outlier

Data yang dihapus: 11 baris unik (0.75% data).

Hasil akhir: Shape **(1449, 76)**.

5 Transformasi Data

5.1 Pemisahan Fitur dan Target

- **Fitur (X):** Semua kolom kecuali `Id` dan `SalePrice` → shape **(1449, 74)**
- **Target (y):** `SalePrice` → shape **(1449,)**

5.2 One-Hot Encoding

38 kolom kategorik ditransformasi menggunakan `pd.get_dummies(drop_first=True)`.

Hasil: Shape X berubah dari **(1449, 74)** → **(1449, 242)**.

5.3 Standarisasi Numerik

Standarisasi menggunakan `StandardScaler` (z-score): $z = \frac{x-\mu}{\sigma}$

Verifikasi:

- Mean rata-rata: **0.0**
- Std rata-rata: **1.0003**
- Shape: **(1449, 242)**

6 Reduksi Dimensi

6.1 Analisis Korelasi

Ditemukan **33 pasangan fitur dengan korelasi > 0.85**.

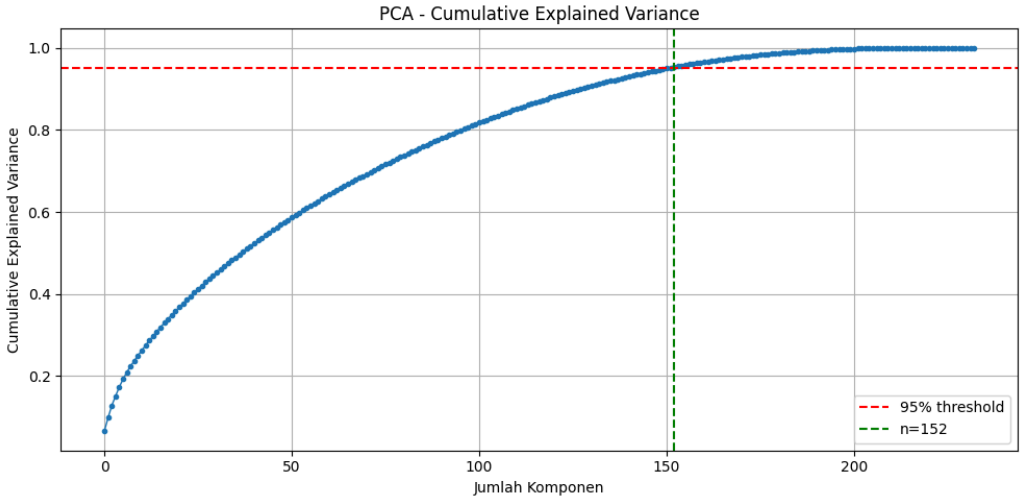
Keputusan: Hanya fitur **numerik asli yang redundan** yang dihapus. Korelasi dari *one-hot encoding* bukan redundansi asli.

9 fitur yang dihapus: `GarageArea`, `TotRmsAbvGrd`, `1stFlrSF`, `GarageYrBlt`, `PoolArea`, `MiscVal`, `LowQualFinSF`, `3SsnPorch`, `ScreenPorch`

Hasil: Shape X → **(1449, 233)**

6.2 Principal Component Analysis (PCA)

PCA diterapkan dengan threshold **95% cumulative variance**.



Gambar 4: PCA cumulative explained variance

Metrik	**Nilai**
Fitur sebelum PCA	233
Komponen untuk 95% variance	152
Shape X setelah PCA	(1449, 152)
Total variance terjaga	0.9511 (95.11%)

Tabel 6: Hasil reduksi dimensi dengan PCA

PCA berhasil mereduksi **233 → 152 komponen** sambil mempertahankan 95% informasi.

7 Dataset Akhir

Tahap	Shape	Aksi
Awal	(1460, 81)	—
Drop kolom >50% missing	(1460, 76)	Hapus 5 kolom
Handle sisa missing	(1460, 76)	Isi 0 missing value
Drop outlier ekstrem	(1449, 76)	Hapus 11 baris
One-Hot Encoding	(1449, 242)	Tambah 168 kolom binary
Standarisasi	(1449, 242)	Mean=0, std=1
Drop fitur korelasi	(1449, 233)	Hapus 9 fitur redundan
PCA (95%)	**(1449, 152)**	**Reduksi dimensi**

Tabel 7: Ringkasan tahapan praproses data

7.1 File Output

1. `5054251031_BimaSatriawan_Tugas_Praproses_Data.csv` - Dataset lengkap (sebelum PCA), shape (1449, 234)
2. `5054251031_BimaSatriawan_Tugas_Praproses_Data_PCA.csv` - Dataset PCA, shape (1449, 153)

8 Kesimpulan

1. **Pembersihan data**: 5 kolom dihapus, 14 kolom di-handle. Hasil: **0 missing values**.
2. **Outlier**: 11 baris ekstrem dihapus (0.75%).
3. **Transformasi**: *one-hot encoding* dan *StandardScaler*. Shape: 74 $\rightarrow$ 242.
4. **Reduksi dimensi**: korelasi hapus 9 fitur, PCA reduksi 233 $\rightarrow$ 152 komponen dengan **95.11% variance**.