Laporan Praktikum 5

Sequential Pattern Analysis

Dataset: Online Retail - Sequential Pattern Mining

Bima Satriawan
NRP: 5054251031

1. Pendahuluan

1.1. Latar Belakang

Sequential Pattern Analysis digunakan untuk menemukan pola pembelian yang berurutan dari waktu ke waktu. Pada konteks bisnis ritel, pola ini dapat digunakan untuk memahami urutan produk yang dibeli pelanggan pada invoice yang berbeda.

Pada praktikum ini, data transaksi Online Retail disusun menjadi sequence per pelanggan berdasarkan CustomerID dan InvoiceDate. Setiap sequence berisi daftar itemset yang urut secara waktu. Pola berurutan kemudian diekstraksi dengan algoritma PrefixSpan dan dievaluasi berdasarkan support dan confidence.

1.2. Tujuan

Tujuan praktikum ini adalah:

1. Memahami konsep Sequential Pattern Analysis dan aplikasinya dalam data mining.
2. Menerapkan algoritma Sequential Pattern Mining seperti PrefixSpan pada dataset transaksi.
3. Mengevaluasi pola berurutan yang ditemukan berdasarkan metrik support dan confidence.

1.3. Konsep Dasar Sequential Pattern Analysis

Support mengukur proporsi pelanggan yang memuat pola tertentu.

$$\text{support}(X) = \frac{n(X)}{N}$$

Confidence mengukur proporsi pelanggan yang melanjutkan ke itemset berikutnya setelah memiliki prefix pola.

$$\text{confidence}(X \rightarrow Y) = \frac{n(X \rightarrow Y)}{n(X)}$$

dengan X adalah prefix pola dan $X \rightarrow Y$ adalah pola penuh. Support dan confidence perlu dibaca bersama agar pola yang dipilih tidak hanya sering muncul tetapi juga konsisten.

2. Eksplorasi Awal Dataset

Dataset yang digunakan adalah Online Retail dengan 541.909 baris dan 8 kolom. Struktur atribut dataset ditampilkan pada Tabel 1.

Tabel 1: Struktur atribut dataset Online Retail

No.	Kolom	Tipe Data	Keterangan
1	InvoiceNo	Object	Nomor unik transaksi atau invoice
2	StockCode	Object	Kode unik produk
3	Description	Object	Nama atau deskripsi produk
4	Quantity	Integer	Jumlah unit produk dalam transaksi
5	InvoiceDate	Object	Waktu terjadinya transaksi
6	UnitPrice	Float	Harga per unit produk
7	CustomerID	Float	Identitas pelanggan
8	Country	Object	Negara pelanggan

2.1. Missing Values

Pemeriksaan missing value menemukan nilai kosong pada CustomerID dan Description. Hasil lengkap ditampilkan pada Tabel 2.

Tabel 2: Hasil pemeriksaan missing values

Kolom	Jumlah Missing	Persentase	Keputusan
CustomerID	135.080	24,93%	Dihapus
Description	1.454	0,27%	Dihapus
InvoiceNo	0	0,00%	Dipertahankan
StockCode	0	0,00%	Dipertahankan
Quantity	0	0,00%	Dipertahankan
InvoiceDate	0	0,00%	Dipertahankan
UnitPrice	0	0,00%	Dipertahankan
Country	0	0,00%	Dipertahankan

Missing value pada CustomerID dihapus karena sequence disusun per pelanggan. Baris dengan Description kosong dihapus karena nama produk tidak dapat diidentifikasi.

3. Pembersihan Data

3.1. Kriteria Pembersihan

Pembersihan dilakukan dengan menghapus baris yang memenuhi sedikitnya satu kondisi berikut.

1. InvoiceNo kosong.
2. Description kosong.
3. InvoiceNo diawali huruf C (transaksi pembatalan).
4. Quantity kurang dari atau sama dengan nol.
5. CustomerID kosong.

3.2. Hasil Pembersihan

Perbandingan jumlah baris, invoice, dan pelanggan sebelum dan sesudah pembersihan ditampilkan pada Tabel 3.

Tabel 3: Perbandingan data sebelum dan sesudah pembersihan

Kondisi	Baris	Invoice	Pelanggan
Sebelum pembersihan	541.909	25.900	4.372
Sesudah pembersihan	397.924	18.536	4.339
Tidak dipertahankan	144.000	7.364	33

4. Persiapan Data untuk Sequential Pattern Mining

Data diurutkan berdasarkan CustomerID dan InvoiceDate. Item pada satu invoice dikelompokkan menjadi satu itemset. Setiap pelanggan diubah menjadi satu sequence berisi daftar itemset yang urut secara waktu. Sequence disimpan dalam bentuk list of list agar dapat diproses dengan pustaka prefixspan.

Jumlah sequence yang terbentuk sama dengan jumlah pelanggan unik yang dipertahankan, yaitu 4.339 sequence.

5. Penerapan Algoritma PrefixSpan

5.1. Parameter Algoritma

Parameter PrefixSpan yang digunakan ditampilkan pada Tabel 4.

Tabel 4: Parameter PrefixSpan

Parameter	Nilai
Minimum support	0,01
Jumlah sequence	4.339
Minimum count	44

Minimum support sebesar 0,01 berarti pola harus muncul pada sedikitnya 1 persen pelanggan. Batas tersebut setara dengan 44 pelanggan.

5.2. Hasil Pola Berurutan

PrefixSpan menghasilkan 2 pola yang memenuhi minimum count. Kedua pola memiliki panjang satu itemset. Hasil lengkap ditampilkan pada Tabel 5.

Tabel 5: Pola berurutan yang ditemukan dengan minimum support 0,01

Pola	Pelanggan	Support	Panjang
Manual	49	0,0113	1 itemset
POSTAGE	45	0,0104	1 itemset

Tidak ada pola dengan panjang minimal dua itemset yang memenuhi minimum support.

6. Evaluasi Pola Berurutan

6.1. Pola Terbaik

Kedua pola yang ditemukan dipilih sebagai pola terbaik karena merupakan satu-satunya pola yang memenuhi minimum support. Kedua pola berupa itemset tunggal, yaitu Manual dan POSTAGE. Support pola Manual sebesar 0,0113 menunjukkan bahwa itemset tersebut muncul pada 49 dari 4.339 pelanggan. Support pola POSTAGE sebesar 0,0104 menunjukkan bahwa itemset tersebut muncul pada 45 dari 4.339 pelanggan.

Karena panjang kedua pola hanya satu itemset, nilai confidence tidak dapat dihitung dengan cara prefix dan pola penuh. Confidence untuk pola dengan satu itemset setara dengan support-nya sendiri.

6.2. Keterbatasan Analisis

Tidak ada pola berurutan dengan panjang dua atau lebih yang terbentuk. Hal ini disebabkan oleh representasi itemset sebagai tuple utuh seluruh produk dalam satu invoice. Karena isi invoice pada umumnya berbeda antar pelanggan, itemset yang identik jarang muncul berulang. Akibatnya pola berurutan dengan panjang dua atau lebih sulit terbentuk.

Untuk memperoleh pola berurutan yang lebih bermakna, dua penyesuaian dapat dilakukan sesuai ketentuan praktikum yang membolehkan penyesuaian nilai support ketika pola yang dihasilkan terlalu sedikit.

1. Menurunkan minimum support, misalnya menjadi 0,002 atau 0,001.
2. Mengubah representasi sequence dari itemset utuh menjadi daftar item datar per pelanggan dengan urutan waktu invoice tetap terjaga.

6.3. Implikasi Bisnis

Pola yang ditemukan menunjukkan produk atau kombinasi produk yang sering dibeli pelanggan, yaitu Manual dan POSTAGE. Kedua itemset tersebut dapat dipertimbangkan sebagai produk pendukung dalam rekomendasi, tetapi belum menggambarkan urutan pembelian antar waktu. Untuk implikasi bisnis yang lebih kuat pada urutan pembelian,

representasi sequence perlu disesuaikan agar pola berurutan dengan panjang dua atau lebih dapat terbentuk.

7. Kesimpulan

1. Dataset awal memiliki 541.909 baris dan 4.372 pelanggan unik.
2. Pembersihan menghapus baris dengan Description kosong, invoice pembatalan, Quantity nonpositif, dan CustomerID kosong.
3. Setelah pembersihan diperoleh 397.924 baris dan 4.339 pelanggan yang menjadi dasar penyusunan sequence.
4. Setiap pelanggan diubah menjadi satu sequence berisi daftar itemset yang urut secara waktu.
5. PrefixSpan dengan minimum support 0,01 menghasilkan 2 pola berurutan dengan panjang satu itemset, yaitu Manual dan POSTAGE.
6. Tidak ada pola berurutan dengan panjang dua atau lebih yang memenuhi minimum support karena representasi itemset utuh membuat itemset jarang berulang antar pelanggan.
7. Untuk analisis sequential pattern yang lebih bermakna, representasi sequence perlu diubah ke level item atau minimum support perlu diturunkan.
8. Pola berurutan yang lebih baik dapat digunakan untuk memahami urutan pembelian pelanggan, menyusun strategi rekomendasi produk lanjutan, dan merancang promosi yang mempertimbangkan urutan waktu pembelian.